

Применение обучения с подкреплением в исследовании игр в автобаттлерах

Пономарев Тимур Евгеньевич
БПМИ243

НИУ ВШЭ, Факультет компьютерных наук
Руководители: к.ф.-м.н. П. В. Кудеров, ст. преп. М. К. Горденко

Москва, 2026

Среда: Hearthstone Battlegrounds (HS:BG) — автобаттлер от Blizzard, >20 млн игроков/мес.

Две фазы:

- **Recruit:** покупка/продажа юнитов, reroll, апгрейд таверны, расстановка
- **Combat:** автоматический бой двух досок

Почему интересно как RL-задача:

- Богатый testbed: POMDP + стохастика + комбинаторный action space + экономическое планирование
- Структурно богаче Pokemon [Guo, RLC 2025] — есть экономика и позиционирование
- Жанр живой: Blizzard добавляет карты каждый сезон $\Rightarrow$ бенчмарк растёт вместе со средой

Цель: разработать исследовательскую платформу и обучить агента, способного вырабатывать конкурентоспособную стратегию в автобаттлерах.

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma), \quad \gamma = 0.99$$

$\mathcal{S} = \mathbb{R}^{1009}$ — структурированное наблюдение:

Компонент	Размер
Global (HP, золото, тир, флаги)	7
Board (7×37)	259
Hand (10×37)	370
Store (7×37)	259
Discover (3×37)	111
Enemy info	3
Итого	1 009

$\mathcal{A} = \mathbf{Discrete}(32)$ с динамической маской:

- 0: End Turn
- 1: Roll
- 2–8: Buy / Target
- 9–15: Sell
- 16–25: Play Hand
- 26–31: Swap

R : terminal ± 5 , r_{combat} , $r_{synergy}$, r_{board} , $r_{economy}$

Что делает задачу сложной:

- **POMDP**: доска оппонента видна только в бою
- **Стохастика**: атаки рандомны, reroll рандомен
- **Комбинаторика**: $C_{18}^7 \cdot 7! \sim 1.6 \cdot 10^8$ конфигураций доски
- **Sparse reward**: итог через 10–15 раундов (credit assignment)

Существующие open-source среды:

- **Fireplace** — классический HS, нет BG
- **Unity ML-Agents** — 10–50 игр/с (графика)
- **HSReplay / Firestone** — только реплеи, нет интеракции
- **Leiden** [Ren 2022], **LUT** [Zhang 2024] — упрощения: без аур, Discovery, позиций

⇒ пишем собственный движок с полной боевой системой

~3 500 LOC движка + 839 LOC Gymnasium-обёртки, 11 модулей, 13 тестовых модулей (цифры из отчёта). Существующие open-source BG-среды (Leiden 2022, LUT 2024) используют упрощённые правила — без аур, Discovery, цепных Deathrattle, позиционных эффектов. **Моя** — **наиболее полная по охвату механик** на момент написания отчёта.

Подсистемы:

- **Entities:** Buff Layer Stack (5 слоёв)
- **Event System:** приоритизированная очередь, 17 типов событий, детерминированная сортировка (group, priority, side, slot, uid)
- **Combat:** 10 механик (Deathrattle, Reborn, Divine Shield, Cleave, Poisonous, Windfury, Taunt, Magnetize, Avenge, Immediate Attack)
- **Auras:** stateless пересчёт
- **Tavern:** Buy/Sell, Triples, Discovery, Spells, Freeze, Tier-up
- **Gym wrapper:** Action Masking, детерминизм

Buff Layer Stack:

Слой	Время жизни
Базовый	неизменяемый
Перманентный	навсегда
Ходовой	до конца хода
Боевой	до конца боя
Аурный	пересчёт при любом изменении доски

Аналогов в open-source не обнаружено.

Архитектуры: MLP vs Transformer — обоснование

MLP на плоском $\mathbb{R}^{1009}$: не видит границы зон, не ловит set-взаимодействия (синергии, Baron+Deathrattle), тратит параметры на padding.

Токенизация $\mathbb{R}^{1009}$ для Transformer:

- **27 entity-токенов:** Board (7) + Hand (10) + Store (7) + Discover (3), каждый слот $\rightarrow$ 37 признаков
- **+ 1 [GLOBAL_CTX] токен:** $\text{MLP}(\text{Global}_7 \oplus \text{Enemy}_3) \in \mathbb{R}^{d_{\text{model}}}$
- $\Rightarrow$ **28 токенов $\times$ 128 $\rightarrow$ DecomposedEncoder $\rightarrow$ FiLM $\rightarrow$ 4 $\times$ GTrXL $\rightarrow$ PMA $\rightarrow$ features**

Компоненты (все из state-of-the-art 2018–2024):

DecomposedEncoder [MARL-GPT 2024]	раздельные проекции continuous / binary / race $\rightarrow$ суммирование
FiLM $(\gamma + 1) \odot x + \beta$ [Perez 2018]	мультипликативная модуляция токенов глобальным контекстом
[GLOBAL_CTX] [AlphaStar 2019]	карты <i>обращаются</i> к макро-контексту внутри Attention
GTrXL-шлюз [Parisotto 2020]	$b_{\text{init}} = -3$: шлюз закрыт на старте, градиенты открывают постепенно
Multi-Seed PMA [Set Transformer 2019]	$K=4$ seed-векторов: агрегация множества карт переменного размера

~ 600 k параметров. **Компоненты известны из литературы, но собраны вместе под автобаттлеры впервые.**



WandB: `custom/max_board_power` и `custom/avg_board_power`.
Transformer — оранжевая (обучение остановлено на 300k шагов), MLP — розовая (1.5M шагов)

	MLP	Transformer
Шаги до плато	400k	80k
Inference FPS	1200	250
Wall-clock	333 с	320 с

Ускорение $\sim 5\times$ по sample efficiency.

Три фазы обучения (Transformer в ~ 5 раз быстрее):

- 1 тратить золото
- 2 синергии и триплеты
- 3 финальная шлифовка

Про FPS: MLP compute-bound на мелких матрицах (GPU простаивает), Transformer честно грузит GPU и масштабируется. **С ростом compute Transformer будет только быстрее MLP.**

Результат 2: PvP — Transformer vs MLP

Прямое столкновение обученных агентов (MLP 1.5М шагов, Transformer 300k):


Игра	HP Transformer	HP MLP	Результат
1	22	21	таймаут
2	30	25	таймаут
3	24	27	таймаут

Все три партии ушли в таймаут (> 500 ходов). Ни один агент не смог добить другого.

Интерпретация:

- Обе архитектуры **“решили”** текущую среду: при 18 картах и тирах 1–3 пространство стратегий слишком узкое
- Движок работает корректно: нет эксплойтов, стабильное равновесие
- **Мотивация для продолжения:** расширить пул карт и тиры (см. апдейты)

Валидация Transformer: attention по слоям



Что видно:


- Layer 0: доска смотрит сама на себя + на [CTX]
- Layer 3: доска ↔ магазин (cross-zone)

Вывод: сеть учит

осмысленные

взаимодействия, а не шум.

Валидация Transformer: специализация голов Layer 0



Головы
специализировались:

- Head 0: внутри доски
- Head 1: магазин
- Head 3: [CTX] + Discovery

Никто не заставлял — PPO
gradient нашёл разделение
труда сам.

Reward shaping в sparse-средах — **признанная открытая задача RL** [Sutton & Barto; Ng 1999 PBRs; Andrychowicz HER 2017].

Что пробовали:

- ❶ **5-компонентный shaping** (в отчёте): $r = r_{combat} + r_{economy} + r_{board} + r_{terminal} + r_{synergy}$ — работал на малом пуле карт
- ❷ **MC Oracle PBRs** — dense reward через C++ Monte-Carlo симуляцию исходов боёв. Ради него написан C++-порт combat. При росте пула значимого выигрыша не дал
- ❸ **Sparse + tier-based curriculum** — текущий подход: агент начинает с тиров 1–2, пул расширяется по мере сходимости

Частичный ablation: MLP vs Transformer + три конфигурации reward. **В рамках вычислительного бюджета данного исследования полная покомпонентная абляция нецелесообразна**; фокус сделан на proof-of-concept архитектуры и валидации sample efficiency. Выбор компонент обоснован литературным обзором 60+ работ (см. [theory/transformer_scaling_research.md](#)).

Сделано после сдачи отчёта:

- Пул карт расширен с ~ 18 до **175 карт**, тирь **1–7**
- Combat engine портирован на **C++** через **pybind11**: **270k+ боёв/с** (90k на сложных кейсах) — $\sim 40\times$ к прошлой C++-версии, $\sim 800\times$ к Python
- **Tier-based curriculum learning**:
HearthstoneEnv(max_tier)
- **Categorical Critic** (DreamerV3): 255 бинов, symlog two-hot, cross-entropy loss
- **Кодовая база выросла**: с 3.5 k LOC до ~ 10.7 k Python + 3.7 k C++ + 9.8 k тестов; тестов — с 13 до **24 модулей / 762 теста**

Future Work:

- **Авторегрессионный action space SAINT** [Wen 2025] + Pointer Networks [Vinyals 2015]
- **RMCTS** [Luo 2025] + Latent Battle Predictor (MuZero-style [Schrittwieser 2020])
- Пайплайн **BC** $\rightarrow$ **PPO** $\rightarrow$ **Self-Play** по образцу Pokemon [Guo RLC 2025]
- **Opponent modeling**: байесовский классификатор архетипов, DTQN [Esslinger 2022] для памяти

- 1 **Headless-среда HS:BG с наиболее полным охватом механик:** 10 боевых механик (Deathrattle, Reborn, Divine Shield, Cleave, Poisonous, Windfury, Taunt, Magnetize, Avenge, Immediate Attack), приоритизированная event-система, ауры, экономика, Action Masking, Gymnasium-API. **~3 500 LOC движка + 839 LOC env** (по отчёту). В отличие от существующих работ (Leiden 2022, LUT 2024), реализованы ауры, Discovery и позиционные эффекты.
- 2 **Transformer-экстрактор под автобаттлеры:** DecomposedEncoder + FiLM + [GLOBAL_CTX] + GTrXL + Multi-Seed PMA. Компоненты взяты из state-of-the-art работ 2018–2025 гг. (AlphaStar, Set Transformer, GTrXL, MARL-GPT). Для жанра автобаттлеров attention-based экстрактор с таким охватом компонент — новая сборка.
- 3 **Экспериментальная валидация на реальных WandB-логах:** Transformer достигает того же плато в $\sim 5\times$ **быстрее** по sample efficiency (80k vs 400k шагов). Attention-анализ показал *самоорганизованную специализацию голов*: head 0 — внутри доски, head 1 — магазин, head 3 — глобальный контекст.

Спасибо за внимание